

NOSQL & INTRO DATA SCIENCE
STATISTICS

POTENCIALIZANDO O DESEMPENHO COM NOSQL



1

LISTA DE IMAGENS

Figura 1 - NoSQL	4
------------------------	---

EXEMPLO

SUMÁRIO

POTENCIALIZANDO O DESEMPENHO COM NOSQL	4
1 PLATAFORMA DE E-COMMERCE DA EMPRESA MELHORES COMPRAS.....	4
1.1 Momento atual do projeto	4
1.2 Detalhando a necessidade da empresa	6
2 ENTREGAS ESPERADAS.....	10

EMANIP

POTENCIALIZANDO O DESEMPENHO COM NOSQL

1 PLATAFORMA DE E-COMMERCE DA EMPRESA MELHORES COMPRAS

1.1 Momento atual do projeto



Figura 1 - NoSQL
Fonte: Google

Os executivos da Melhores Compras estão entusiasmados com as entregas feitas até o momento. A virtualização transformou o projeto, trazendo agilidade e flexibilidade aos negócios: claramente a escalabilidade de recursos está sendo muito bem administrada depois desse passo. Os clientes estão utilizando com mais intensidade os novos recursos, aumentando o tempo de uso da plataforma de e-commerce, tornando essa entrega, até o momento, um grande sucesso. O resultado até o momento é muito bom e a plataforma está com expressivo aumento nas vendas - bem acima de 22%.

Gratidão pela sua contribuição!

Tudo isso está acontecendo porque os entregáveis da fase anterior estão fazendo a diferença e os gestores da Melhores Compras estão com os olhos brilhando com tantas oportunidades que a área de tecnologia pode proporcionar em relação ao negócio. A nova versão do projeto do e-commerce, que contempla as imagens e vídeos, a implementação de programação em banco de dados relacional e a virtualização do ambiente produtivo, trouxe benefícios para garantir dados mais

eficientes e processamento avançado, ou seja, o e-commerce da Melhores Compras está sendo aprimorado a cada fase. Tudo isso tem como maior objetivo fidelizar os seus clientes.

Porém, existem algumas situações que merecem atenção e, apesar do aumento nas vendas da plataforma, ocorreu também proporcional aumento do número de chamados de clientes e funcionários em relação à perda de desempenho - ou até mesmo travamento da plataforma - no momento em que os clientes estão tentando adquirir produtos, ou mesmo quando os funcionários estão realizando acessos administrativos. Apesar da escalabilidade dos ambientes virtuais estar ativada, a área de TI continuava a ser acionada pela perda de desempenho.

Para averiguar esses fatos foi aberta uma investigação profunda pela área de TI para entender o que está acontecendo e, após 20 dias de análise, um relatório apontou algumas situações atípicas que estão ocorrendo e influenciando negativamente a plataforma. Algumas delas citamos a seguir:

- Nos últimos meses, o volume de dados armazenados na plataforma aumentou exponencialmente devido ao aumento significativo nas vendas e no número de acessos. Isso tem impactado especialmente em situações como os cálculos de recomendações ou a verificação da disponibilidade de produtos no estoque, que agora levam muito mais tempo para fornecer uma resposta.
- Atualmente, todos os dados estão sendo armazenados em um típico SGBDR, e os acessos a esses dados por meio de instruções SQL estão consumindo muitos recursos do ambiente, algo que anteriormente não ocorria.
- A última campanha feita para o Dia das Mães foi lançada com descontos em diversos produtos interligados por meio do uso de técnicas de vendas como cross selling e up selling. Apesar de ter sido um sucesso de vendas, houve um abandono expressivo de potenciais clientes (algo próximo de 22%) que desistiram da compra devido à demora da plataforma para realizar o cálculo do valor promocional de cada produto.

O laudo final apontou claramente que o volume de dados e a concentração dos dados exclusivamente em SGBD Relacionais são os principais vilões nesse momento. Para permitir que a empresa continue sendo competitiva e consiga prosperar, será necessário investir tempo de estudo e explorar novas formas de armazenamento.

A área executiva está muito satisfeita com o desempenho das vendas realizadas até o momento – já alcançou todas as metas de vendas. Mas a Melhores Compras espera crescer muito ainda, por isso a área executiva pediu à TI ajuda para conhecer melhor os dados de vendas até o momento. Neste sentido, o seu grupo será convidado a descrever esses dados, dando visibilidade do comportamento à área de negócio como as vendas estão se comportando.

Bora lá!

1.2 Detalhando a necessidade da empresa

Em uma reunião executiva realizada na empresa Melhores Compras, surgiu o interesse em diminuir a taxa de abandono de clientes na fase de compra devido à lentidão encontrada em determinados momentos na plataforma de e-commerce. Atualmente, milhares de reais estão deixando de entrar no caixa da empresa devido a essas perdas, e precisamos que a tecnologia deixe de ser um entrave e se torne um facilitador para apoiar as decisões do negócio.

As necessidades de negócio somaram-se a esta situação: a empresa irá disponibilizar em breve um serviço revolucionário, que possibilitará ao cliente optar por receber em até 24h o produto adquirido, o que deve provocar um novo aumento no acesso à plataforma e nas vendas.

Claro que essa notícia é motivo de comemoração, principalmente para uma empresa que não esperava cumprir todas as suas metas comerciais em um curto espaço de tempo. Porém, do outro lado, a chegada dessa nova funcionalidade pode trazer graves consequências, dado que atualmente já existe um considerável aumento das reclamações sobre falta de desempenho da plataforma, feitas tanto pelos clientes quanto pelos funcionários.

Após uma importante reunião técnica com a participação de profissionais tecnicamente qualificados, decidiu-se inicialmente que será necessário explorar novas estruturas de armazenamento de dados, e os bancos de dados NoSQL foram escolhidos para contribuir nesses estudos. Caso o resultado seja positivo, os escolhidos serão incorporados e acoplados à plataforma de e-commerce.

Para realizar a atividade prática e identificar quais bancos de dados NoSQL atendem melhor à necessidade, três cenários foram criados pela área de negócio e serão usados como prova de conceito para aplicação da sua proposta de solução tecnológica. São eles:

* As provas de conceito são muito importantes na empresa pois permitem que a área técnica verifique se a solução proposta irá funcionar.

1º cenário: Quando um cliente seleciona um produto, a plataforma de e-commerce exibe, adicionalmente, recomendações de outros itens, baseadas nas compras de quem comprou esse produto e em outras promoções correlatas. No contexto atual, esse cálculo está demorando muito tempo para ser feito utilizando estruturas relacionais, dado o volume de dados envolvidos.

Para esse primeiro cenário, a TI propôs o uso de um banco de dados NoSQL do tipo GRAFO.

2º cenário: A definição da entrega de um produto em 24h depende da disponibilidade de estoque do centro de distribuição mais próximo do endereço de entrega. Se o cliente optar por essa entrega *fast*, é necessário realizar a reserva no centro de distribuição e, automaticamente, atualizar o estoque para atender a outros clientes. Nos testes preliminares com o uso do modelo relacional, o desempenho foi frustrante, influenciado principalmente pelo volume de dados e frequência de atualização.

Para esse segundo cenário, a TI propôs o uso de um banco de dados NoSQL do tipo COLUNAR.

3º cenário: A tela de detalhes de um produto sempre recebe novas informações e, hoje em dia, possui informações que podem ser armazenadas juntamente com o produto, tais como: reviews do produto; suas versões; informações de entrega; imagens; recomendações; dicas, entre outras.

Para esse terceiro cenário, a TI propôs o uso de um banco de dados NoSQL do tipo DOCUMENTO.

A primeira parte do desafio está relacionada à estrutura de armazenamento dos dados. Diante dos três cenários acima descritos, você deverá:

- 1) Examine a proposta de uso de banco de dados NoSQL para cada cenário e justifique a escolha feita destacando as características do banco escolhido comparativamente com o cenário apresentado. Como exemplo prático, cite uma empresa real que utiliza o banco de dados proposto.

Com os dados de vendas disponíveis e a área de negócio expandindo seus olhares para entendimento do comportamento das vendas, vamos iniciar a segunda parte do desafio: será que conseguiremos descobrir algo sobre essas vendas?

A área de análise de dados está em franca expansão e existem dezenas de formas de realizar esse estudo. Técnicas como testes de hipóteses, média e mediana, análise descritiva (amplitude total, desvio padrão e variância) são métodos importantes, e talvez por aqui, seja possível iniciar nossa jornada.

A variabilidade dos dados determina o comportamento de consumo dos clientes, mas não podemos nos esquecer de separar os outliers, ou seja, as possíveis distorções que podem fazer com que nossa análise não fique dentro de um equilíbrio adequado para os estudos, e os dados *missing*, que merecem nossa atenção nessa fase.

O seu segundo desafio será analisar os dados de vendas desde 2019 e responder as perguntas abaixo utilizando a linguagem de programação Python para preparar e analisar os dados:

- 2) Analise os dados na perspectiva da coluna quantidade. Existem outliers nos dados disponibilizados? É possível identificar algo em relação às vendas associadas a estes outliers? Justifique sua resposta. Calcule uma estimativa de variabilidade que ignore o efeito desses outliers.

- 3) Em relação à média de preço, há diferença estatisticamente significativa entre a média de preço de alguma região e a média da população? E em relação à

média de preço de alguma modalidade de pagamento e à média da população? Justifique a hipótese.

4) Calcule a matriz de correlação dos dados fornecidos. Quais as variáveis que apresentam forte correlação positiva ou negativa? Acrescente a matriz de correlação como uma imagem e anexe-a ao seu relatório.

EMSE

2 ENTREGAS ESPERADAS

São esperados como entrega **2 arquivo distintos**:

a) A partir do template disponibilizado em word (*.docx), preencha o nome completo e RM dos alunos do grupo. Coloque em ordem alfabética de nome. Siga as instruções preenchendo cada seção do template relativo às duas partes do desafio: a prova de conceito e a análise de dados.

A partir do word (*.docx), gere um arquivo pdf (.pdf) com o nome `<nome_grupo>_PBL_TSCO_1o_Ano_Fase5.pdf`

b) Disponibilize os códigos-fonte Python usados na parte 2 do desafio em um arquivo `<nome_grupo>_PBL_TSCO_1o_Ano_Fase5.ipynb`

Visando contribuir com sua entrega, temos a seguir uma imagem contendo um exemplo hipotético com o resultado da entrega do segundo desafio:

```
# contar as linhas
missings_por_linha = pd.DataFrame({'id': dados_hatco['id'].tolist(),
                                   'n_missings': dados_hatco.isna().sum(axis=1).tolist()})
n_colunas = dados_hatco.shape[1] - 1

# verificar os resultados
missings_por_linha \
    .assign(perc_missings = missings_por_linha['n_missings'] / n_colu
nas) \
    .sort_values('perc_missings', ascending = False) \
    .head(10)
```

Código-fonte 3 – Obtenção das linhas com *missings*
Fonte: Elaborado pelo autor (2022)

#dica: lembre-se de fazer comentários relativos à sua análise.

Exemplo do resultado obtido:

id	n_missings	perc_missings
263	7	0.636364
210	7	0.636364
214	6	0.545455
261	6	0.545455
245	5	0.454545
233	5	0.454545

Figura 11 – Número de linhas com *missings*
Fonte: Elaborado pelo autor (2022)

Realize o upload na plataforma FIAP On conforme orientação da atividade.

Importante: não serão aceitas entregas por meio de links. A entrega deverá ser realizada por meio do upload dos arquivos solicitados na plataforma ON.

Uau! Quantas atividades profissionais, estamos melhorando a cada dia. Espero que esteja tudo mais claro agora, bons estudos e não se esqueça: se precisar de algo procure o seu tutor para pronto atendimento.

A Melhores Compras deseja um bom desafio ao grupo!