

Abrir online:

<https://docs.google.com/document/d/16MslMrginJsKlKdEbOjPKlLoaeNRloI23WguMmhE4Gw/edit?tab=t.0>



TEMPLATE - ARQUITETANDO O UNIVERSO BIG DATA DA MELHORES COMPRAS

Gabriel da Mata Scarpino - 567710

Monalisa Santos Brasileiro - 567495

Renan Assis Rocha - 567431

Vinicius Eduardo Ferreira - 568117

Wellington Barbosa da Silva Lima - 568127

Versão 1

HISTÓRICO DE VERSÕES

[illegible]

FICHA CATALOGRÁFICA

[NÃO PREENCHER - PARA USO DO DEPTO DE EAD E BIBLIOTECA]

A000a Sobrenome, Nome

Título [livro eletrônico] / Nome Sobrenome. -- São Paulo : Fiap, 2016.
x MB ; ePUB

Bibliografia.

ISBN 000-00-00000-00-0

Categoria. 2. Subcategoria. S., Nome. II. Título.

CDU 000.000.00

RESUMO

Template para atividade de PBL fase 6 1º ano TSC.

Palavras-chave: PBL. FASE 6. TEMPLATE

LISTA DE FIGURAS

Figura 1 – Backlog e Atividades no Quadro Kanban	13
Figura 2 - Detalhe item de backlog	13
Figura 3 – Big Data Pipeline Architecture	16
Figura 4 – Big Data Pipeline, diversos vendors	17
Figura 5 – Big Data Pipeline, Open Source Stack	18

LISTA DE QUADROS

Quadro 1 – Quadro resumo das tarefas do PBL

12

LISTA DE TABELAS

Tabela 1 – Origem de Dados	14
Tabela 2 - Dicionário de dados de colunas de tabelas	15

LISTA DE CÓDIGOS-FONTE

No table of figures entries found.

LISTA DE COMANDOS DE PROMPT DO SISTEMA OPERACIONAL

No table of figures entries found.

SUMÁRIO

POTENCIALIZANDO O DESEMPENHO COM NoSQL	11
1 INSTRUÇÕES PARA USO DO TEMPLATE	11
1.1 Template	11
1.1 Instruções	11
2 DESAFIO(S) ENFRENTADO(S) PELA MELHORES COMPRAS	12
2.1 Contextualização do Problema	12
3 PLANEJAMENTO DAS ATIVIDADES	12
3.1 Kanban das Atividades	12
3.2 Detalhamento das Atividades	13
3.3 Link do Kanban	14
4 ORIGEM DOS DADOS	14
4.1 Panorama geral das fontes de dados	14
4.2 Justificativas das Fontes de Dados	14
4.3 Detalhamento das fontes de dados	15
5 ARQUITETURA DE SOLUÇÃO BIG DATA / PIPELINE DE DADOS	16
5.1 Desenho da Arquitetura	19
5.2 Justificativa da Arquitetura	19
5.3 Detalhamento da Arquitetura	19
REFERÊNCIAS	20
GLOSSÁRIO	20

POTENCIALIZANDO O DESEMPENHO COM NoSQL

1 INSTRUÇÕES PARA USO DO TEMPLATE

1.1 Template

Um template é um modelo predefinido que simplifica e padroniza a criação de documentos, páginas da web ou outros elementos de design, permitindo que usuários preencham apenas as partes específicas, economizando tempo e garantindo consistência visual ou estrutural.

Para seu uso leia as instruções nesse e use o template a partir da seção 2

1.1 Instruções

O template está dividido por seções que representam pedidos feitos para o PBL. No template iremos encontrar exemplos ilustrativos de entregas, cujo contexto não tem relação ao que está sendo solicitado no PBL.

Ao usar o template, apague por completo a seção 1 de instruções para que o seu trabalho fique mais organizado.

Não se esqueça de salvar o template em .pdf para a entrega.

A seguir um Quadro Resumo das tarefas:

Para um ou mais problemas a serem resolvidos (ou crie um).

1. Abandono do carrinho de compras em larga escala.
2. Falta de conhecimento do perfil do usuário anônimo e do cliente.
3. Diminuição da taxa de conversão (usuário anônimo para cliente).
4. Estoque ocorrendo rupturas.
5. Aumento considerável no tempo de entrega e crescente aumento de entregas indevidas.
6. Aumento do número de reclamações no SAC.
7. Alto consumo de tempo (inviável) para processamento dos dados.

A partir deles desenvolva os passos:

- Contextualização do problema
- Planejamento de atividades

- Kanban contendo todas as atividades
- Detalhamento da atividade
- Link para navegação no Kanban
- Origem de Dados
 - Panorama Geral das Fontes de Dados
 - Justificativas das Fontes de Dados
 - Detalhamento das Fontes de Dados
- Arquitetura de Solução Big Data / Pipeline de Dados
 - Desenho da Arquitetura (com link opcional)
 - Justificativa da Arquitetura
 - Detalhamento da Arquitetura

Quadro 1 – Quadro resumo das tarefas do PBL

Fonte: Elaborado pelo autora (2024)

2 DESAFIO(S) ENFRENTADO(S) PELA MELHORES COMPRAS

2.1 Contextualização do Problema

Resolver a logística não é apenas uma questão operacional, mas uma necessidade estratégica para a sobrevivência do e-commerce por três motivos fundamentais:

- **Estancamento da Perda Financeira:** Entregas indevidas geram um custo duplo (logística reversa para coletar o item errado e um novo envio para o item correto). Além disso, o aumento no tempo de entrega costuma gerar pedidos de cancelamento e estornos, impactando diretamente o fluxo de caixa.
- **Recuperação da Confiança e Retenção de Clientes:** No e-commerce, a entrega é o único ponto de contato físico com o cliente. Se ela falha ou atrasa, a experiência de compra é arruinada. Corrigir isso é vital para aumentar o *Lifetime Value* (LTV), garantindo que o cliente volte a comprar em vez de migrar para a concorrência.
- **Redução da Sobrecarga no SAC:** Como visto no ponto #6 da sua lista, o número de reclamações no SAC aumentou. Ao resolver o problema das entregas, você reduz drasticamente o volume de chamados de suporte

("Onde está meu pedido?"), permitindo que a equipe de atendimento foque em vendas e casos mais complexos, em vez de apenas gerenciar crises logísticas.

Ao priorizar a eficiência na entrega, a **Melhores Compras** ataca a causa raiz de vários outros sintomas negativos, estabilizando a operação para que a empresa possa voltar a focar em conversão e crescimento.

3 PLANEJAMENTO DAS ATIVIDADES

3.1 Kanban das Atividades




Figura 1 – Backlog e Atividades no Quadro Kanban
Fonte: Elaborado pelos autores (2026)

3.2 Detalhamento das Atividades

A fazer:

A FAZER

Implementar Chatbot de Nível 1

+ Adicionar

Etiquetas

Datas

Checklist

Membros

Descrição

Editar

Criar um fluxo de autoatendimento para dúvidas frequentes (status de pedido, 2ª via de boleto), liberando os atendentes humanos para casos complexos.

Comentários e atividade

Ocultar detalhes

Escrever um comentário...

WL

Wellington Lima

adicionou este cartão a A FAZER

há 58 minutos

A FAZER

Criação de Base de Conhecimento (FAQ)

+ Adicionar

Etiquetas

Datas

Checklist

Membros

Descrição

Editar

Criar um FAQ que reúne as dúvidas mais comuns dos usuários, oferecendo respostas rápidas e diretas para promover o autoatendimento.

Comentários e atividade

Ocultar detalhes

Escrever um comentário...

WL

Wellington Lima

adicionou este cartão a A FAZER

há 52 minutos

A FAZER

Contratação de Ferramenta de Help Desk

+ Adicionar

Etiquetas

Datas

Checklist

Membros

Descrição

Editar

Criar um suporte técnico especializado para resolver os problemas relacionados a TI dos usuários.

Comentários e atividade

Ocultar detalhes

Escrever um comentário...

WL

Wellington Lima

adicionou este cartão a A FAZER

há 52 minutos

Em progresso:

EM PROGRESSO

Treinamento de Atendimento Humanizado

+ Adicionar

Etiquetas

Datas

Checklist

Membros

Descrição

Capacitar a equipe atual em técnicas de empatia e resolução de conflitos para reduzir o "atrito" nas conversas atuais.

Editar

Comentários e atividade

Ocultar detalhes

Escrever um comentário...

WL

Wellington Lima adicionou este cartão a EM PROGRESSO há 52 minutos

EM PROGRESSO

Integração SAC x Logística

+ Adicionar

Etiquetas

Datas

Checklist

Membros

Descrição

Conectar o sistema de atendimento diretamente ao banco de dados da transportadora, para que o atendente tenha a localização exata do produto sem precisar ligar para terceiros.

Editar

Comentários e atividade

Ocultar detalhes

Escrever um comentário...

WL

Wellington Lima adicionou este cartão a EM PROGRESSO há 52 minutos

EM PROGRESSO

Criação de Alça de Feedback (Looping)

+ Adicionar

Etiquetas

Datas

Checklist

Membros

Descrição

Estabelecer uma reunião semanal onde o SAC reporta os 3 problemas mais recorrentes diretamente para os gerentes de Operação e Compras.

Editar

Comentários e atividade

Ocultar detalhes

Escrever um comentário...

WL

Wellington Lima adicionou este cartão a EM PROGRESSO há 52 minutos

Revisão:

REVISÃO ▾

Auditoria de Tickets Resolvidos

+ Adicionar

Etiquetas

Datas

Checklist

Membros

Descrição

Revisar aleatoriamente 5% dos chamados concluídos para garantir que a solução foi definitiva e não apenas um "paliativo"

Editar

Comentários e atividade

Ocultar detalhes

Escrever um comentário...

WL

Wellington Lima adicionou este cartão a REVISÃO há 52 minutos

REVISÃO ▾

Piloto de Pesquisa NPS (Net Promoter Score)

+ Adicionar

Etiquetas

Datas

Checklist

Membros

Descrição

Testar o envio de uma pesquisa de satisfação automática após cada encerramento de chamado para medir a eficácia da equipe.

Editar

Comentários e atividade

Ocultar detalhes

Escrever um comentário...

WL

Wellington Lima adicionou este cartão a REVISÃO há 53 minutos

Concluídos:

CONCLUÍDOS ▾

SLA de Resposta Definido

+ Adicionar

Etiquetas

Datas

Checklist

Membros

Descrição

Estabelecer e cumprir o tempo máximo de 4 horas para a primeira resposta e 24 horas para a solução total.

Editar

Comentários e atividade

Ocultar detalhes

Escrever um comentário...

WL

Wellington Lima adicionou este cartão a CONCLUÍDOS há 53 minutos

CONCLUÍDOS ▾

Unificação de Canais (Omnichannel)

+ Adicionar

Etiquetas

Datas

Checklist

Membros

Descrição

Integrar WhatsApp, Instagram e site em uma única tela, evitando que o cliente faça a mesma reclamação em três lugares diferentes

Editar

Comentários e atividade

Ocultar detalhes

Escrever um comentário...

WL

Wellington Lima adicionou este cartão a CONCLUÍDOS há 53 minutos

3.3 Link do Kanban

<https://trello.com/b/vOHbuaOo/melhoria-no-sac-da-melhores-compras>

4 ORIGEM DOS DADOS

Os dados serão coletados por meio do banco de dados NOSQL MongoDB, que é altamente flexível para trabalhar com dados estruturados, semiestruturados e não estruturados, além de possuir alta velocidade e escalabilidade para trabalhar com big data.

Os dados serão gerados em tempo real de acordo com as interações dos usuários no site das melhores compras, seja pelos pedidos realizados e cancelados, as reclamações recebidas pelo nosso chatbot ou até mesmo dados gerados pelos usuários anônimos. Com isso todos os dados serão coletados em ondas, enviadas 24 vezes ao dia para nosso sistema (24 horas).

4.1 Panorama geral das fontes de dados

Origem	Formato	Velocidade	Volume	Horário Coleta	Localização	Proprietário
Banco de dados MongoDB	BSON	Coletado diariamente por meio de ondas de atualização.	Grande: aproximadamente 100.000 registros por dia	Todos os dias, 24 vezes ao dia em horários aleatórios	Google Cloud Platform	Todo o time de operações da empresa que é responsável por alterar os dados dos produtos.

Tabela 1 – Origem de Dados
Fonte -Elaborado pela autora (2026)

4.2 Justificativas das Fontes de Dados

MongoDB: A empresa lida com um grande volume de dados e que muitas vezes são atualizados em tempo real. O MongoDB lida com dados estruturados,

semiestruturados, e não estruturados de maneira mais eficiente que modelos relacionais. A empresa poderá usar de sua alta escalabilidade e desempenho para otimizar processos e melhorar a experiência do usuário como um todo.

4.3 Detalhamento das fontes de dados

Detalhe as fontes de dados.

Tabela	Apelido	Descrição	Interessados	Dono da informação	Retenção
T_SIC_Produto	Prod	Retém dados de produtos comercializados pela empresa.	Time de operações da empresa.	Time de operações da empresa.	Somente produtos que tenham vendas nos últimos 365 dias são mantidos no sistema. Os demais são considerados descontinuados e podem ser eliminados dos registros. Backup diário full.
T_SIC_Vendas	VD	Retém dados das vendas realizadas no site.	vendedores e time comercial.	time comercial	Produtos cancelados 3 vezes no mesmo dia, serão suspensos do site por tempo indeterminado, podendo serem realocados de forma manual;

Tabela 2 - Dicionário de dados de colunas de tabelas
Fonte - Material da fase – Elaborado pelo autor

5 ARQUITETURA DE SOLUÇÃO BIG DATA / PIPELINE DE DADOS

O objetivo agora é fazer o desenho da sua solução de big data. Inicie o desenho criando a camada de Data Source representando as origens de dados definidas. Descreva os passos da sua arquitetura

Observe com atenção os modelos de Arquitetura de Big Data para base /
inspiração, e desenhe a sua arquitetura de dados, justificando cada passo




Figura 3 – Big Data Pipeline Architecture
Fonte -<http://scgupta.link/big-data-pipeline>




Figura 4 – Big Data Pipeline, diversos vendedores
Fonte -<http://scgupta.link/big-data-pipeline>




Figura 5 – Big Data Pipeline, Open Source Stack
Fonte -<http://scgupta.link/big-data-pipeline>


5.1 Desenho da Arquitetura

Faça o seu desenho.

a) Complemente seu desenho de solução com a camada Data Lake e respectivos formatos de armazenamento, utilizando como premissa as informações da camada de Data Source. A camada Data Lake é responsável por adquirir dados das fontes e, se necessário, convertê-los para um formato adequado à maneira como os dados devem ser analisados. E o melhor, essa camada pode ser distribuída, ou seja, estar localizada em diversos provedores de cloud ou mesmo ser implementada em um modelo híbrido (Cloud e On premise).

b) Incorpore a camada de análise em seu desenho de solução: essa camada lê os dados do Data Lake, aplica algoritmos de análise em busca de insights para melhorar a tomada de decisão.

c) Incorpore a camada de consumo em seu desenho de solução: essa camada tem por objetivo consumir a saída fornecida pela camada de análise nos mais diversos formatos (visualização, KPIs operacionais, alertas de negócio, disponibilizar dados higienizados para machine learning, entre outros).



5.2 Justificativa da Arquitetura

A arquitetura proposta foi definida com base nos princípios de sistemas distribuídos, processamento de dados em larga escala e separação de responsabilidades entre camadas, visando garantir escalabilidade, flexibilidade e eficiência analítica.

O modelo adotado segue o padrão clássico de pipelines de dados, estruturado em **Data Source** → **Ingestão** → **Data Lake** → **Processamento/Análise** → **Consumo**, no qual o Data Lake atua como elemento central da arquitetura. Essa abordagem permite desacoplar as fontes de dados dos mecanismos de processamento e consumo, promovendo maior modularidade e facilidade de evolução.

A escolha do Data Lake como núcleo da solução se justifica pela necessidade de armazenar dados heterogêneos oriundos de um banco NoSQL (MongoDB), que apresenta alta variabilidade estrutural. O Data Lake possibilita o armazenamento no formato bruto (schema-on-read), reduzindo a complexidade na ingestão e permitindo reproprocessamento dos dados conforme novas demandas analíticas surgem.

A organização interna do Data Lake em múltiplas camadas (Raw, Trusted e Refined) segue o conceito amplamente adotado na indústria conhecido como **Medallion Architecture**, ainda que não explicitamente nomeado no diagrama. Essa estrutura permite um fluxo progressivo de refinamento dos dados, garantindo qualidade, rastreabilidade e governança ao longo do pipeline.

Embora o diagrama represente um Data Lake tradicional, a arquitetura pode ser interpretada conceitualmente como uma evolução para o paradigma de **Data Lakehouse**, uma vez que integra armazenamento e processamento analítico de forma unificada, especialmente ao considerar o uso de um Data Warehouse analítico para consultas de alto desempenho.

Adicionalmente, a separação clara entre as camadas e a organização dos dados por domínio (ex.: vendas e produtos) se alinham parcialmente aos princípios de **Data Mesh**, especialmente no que diz respeito à valorização dos dados como ativos estratégicos e à possibilidade de evolução para uma arquitetura orientada a domínios.

A adoção de ingestão híbrida (batch e streaming) permite atender simultaneamente a requisitos de análise histórica e processamento em tempo real, ampliando a capacidade de geração de insights operacionais e estratégicos. O uso de processamento distribuído garante eficiência no tratamento de grandes volumes de dados, enquanto a camada de consumo viabiliza a democratização do acesso à informação.

Dessa forma, a arquitetura proposta equilibra simplicidade estrutural (como representado no diagrama) com aderência a conceitos modernos de engenharia de dados, garantindo robustez, escalabilidade e alinhamento com práticas contemporâneas.

5.3 Detalhamento da Arquitetura

A arquitetura proposta é composta por múltiplas camadas, cada uma com responsabilidades bem definidas, permitindo a construção de um pipeline de dados escalável, resiliente e orientado à geração de valor analítico.

A camada de **captura de dados (Data Source)** considera como principal fonte um banco de dados NoSQL, o MongoDB, responsável por armazenar dados transacionais relacionados a produtos e vendas. Essa camada é caracterizada pela alta variabilidade estrutural dos dados (documentos em formato JSON/BSON), bem como pela geração contínua de eventos provenientes de operações do sistema, como registros de vendas, atualizações de produtos e interações dos usuários. Essa natureza exige uma abordagem flexível de integração, baseada no conceito de *schema-on-read*.

A camada de **ingestão de dados** trata da extração, transporte e entrega dos dados das fontes para o ambiente analítico. Essa camada opera de forma híbrida, combinando ingestão em lote (batch), realizada em intervalos definidos ao longo do dia, e ingestão em fluxo contínuo (streaming), responsável por capturar eventos em tempo real. São utilizados conectores para leitura incremental dos dados e sistemas de mensageria distribuída para garantir desacoplamento, escalabilidade e tolerância

a falhas. Além disso, mecanismos de orquestração são empregados para controlar dependências, agendamento e monitoramento dos pipelines.

A camada de **armazenamento (Data Lake)** é responsável por centralizar os dados em um ambiente distribuído e escalável, utilizando armazenamento de objetos. Os dados são organizados em três níveis: **Raw**, onde são armazenados em seu formato original, garantindo imutabilidade e rastreabilidade; **Trusted**, onde passam por processos de limpeza, padronização e validação, sendo convertidos para formatos otimizados como Parquet; e **Refined**, onde os dados são modelados e estruturados para consumo analítico. Essa organização segue o conceito da *Medallion Architecture*, permitindo um fluxo progressivo de qualidade e governança dos dados.

Para o **processamento de dados estruturados e semiestruturados**, escolhemos um framework de processamento distribuído, como o Apache Spark, devido à sua capacidade de executar transformações complexas em larga escala com alta eficiência. Esse componente permite realizar operações como agregações, junções, enriquecimento de dados e validações, explorando paralelismo e processamento em memória. O processamento ocorre tanto em modo batch quanto em streaming, garantindo suporte a diferentes tipos de workload analítico.

A camada de **análise** é responsável por transformar os dados processados em informações úteis para o negócio. Nessa etapa, os dados refinados são organizados em um Data Warehouse analítico, permitindo a execução de consultas complexas com baixa latência. São realizadas análises descritivas e diagnósticas, como cálculo de indicadores de desempenho, identificação de padrões de consumo e análise de tendências.

A camada de **consumo de dados** tem como objetivo disponibilizar os resultados das análises para diferentes perfis de usuários e sistemas. Isso inclui ferramentas de visualização de dados para criação de dashboards e relatórios gerenciais, além da disponibilização de APIs para integração com outras aplicações. Também contempla o uso de dados refinados em modelos de machine learning, possibilitando a geração de previsões, recomendações e detecção de anomalias.

Por fim, a arquitetura incorpora aspectos transversais como governança de dados, controle de acesso, qualidade dos dados e monitoramento dos pipelines. Esses

elementos garantem confiabilidade, segurança e aderência às boas práticas de engenharia de dados, além de possibilitar a evolução da arquitetura para modelos mais avançados, como Data Lakehouse e Data Mesh.

Dessa forma, cada camada desempenha um papel específico dentro do pipeline, contribuindo para a construção de uma solução robusta, escalável e orientada à tomada de decisão baseada em dados.

REFERÊNCIAS

SOBRENOME, Nome do autor abreviado. **Título do livro**. Local da edição: Editora, ano.

GLOSSÁRIO

Termo	Explicação.
Termo	Explicação.